

یک رویکرد یادگیری عمیق مبتنی بر MRI برای تشخیص دقیق بیماری آلزایمر

نویسنده: فاطمه مظفری، کارشناسی ارشد، دانشگاه آزاد اسلامی، واحد تهران جنوب
مهدی اسلامی، دکتری تخصصی، دانشگاه آزاد اسلامی، واحد علوم و تحقیقات تهران

چکیده

بیماری آلزایمر (AD) شایع ترین نوع زوال عقل است که بر سیستم عصبی تأثیر می گذارد و منجر به کاهش عملکردهای مختلف مغز مانند از دست دادن حافظه می شود. تلاش های تحقیقاتی اخیر بر توسعه روش های غیرتهاجمی برای تشخیص زودهنگام AD متمرکز شده اند، زیرا تشخیص زودهنگام نقش مهمی در افزایش مراقبت از بیمار و نتایج درمان دارد. این مطالعه یک رویکرد مبتنی بر یادگیری عمیق را برای تشخیص دقیق و طبقه بندی مراحل مختلف AD ارائه می کند. روش پیشنهادی از معماری شبکه عصبی کانولوشنال کم عمق (CNN) و تصاویر مغزی تشدید مغناطیسی دوبعدی ۱T (MR) استفاده می کند. این نه تنها تشخیص سریع و دقیق AD را ارائه می دهد، بلکه طبقه بندی جهانی (اختلال شناختی نرمال در مقابل خفیف (MCI) در مقابل AD) و طبقه بندی محلی را امکان پذیر می کند، که شامل طبقه بندی MCI به دمانس بسیار خفیف (VMD)، دمانس خفیف (MD) است. و دمانس متوسط (MoD) به عنوان مرحله پیش از AD. این مطالعه عملکرد این رویکرد را با مدل های پیشرفته یادگیری عمیق مانند DenseNet۱۲۱، ResNet۵۰، VGG ۱۶، EfficientNetB۷ و InceptionV۳ مقایسه می کند. یافته ها دقت و استحکام روش پیشنهادی را با صحت آزمایش کلی ۹۸.۵۰ درصد نشان می دهد.

کلمات کلیدی: بیماری آلزایمر، شبکه کانولوشنی، شبکه از پیش آموزش دیده، یادگیری انتقالی، تصاویر MRI مغزی

۱- مقدمه:

آلزایمر یک بیماری پیشرونده عصبی است که با از دست دادن بافت مغز و مرگ سلول های عصبی مشخص می شود و منجر به زوال شناختی و از دست دادن حافظه می شود که معمولاً به عنوان زوال عقل پیری شناخته می شود [۱]. این بیماری همچنین توانایی بیماران را در انجام کارهای روزانه مانند نوشتن، صحبت کردن و خواندن و همچنین شناخت دوستان و اعضای خانواده مختل می کند. بیماری آلزایمر یک وضعیت عصبی چالش برانگیز است که در درجه اول جمعیت مسن را تحت تأثیر قرار می دهد. این بیماری پس از بیماری قلبی، سرطان و سکته، چهارمین عامل مرگ و میر در جهان است [۱]. تقریباً ۵۰ میلیون نفر در سراسر جهان با زوال عقل زندگی می کنند که اکثریت آنها در کشورهای کم درآمد و متوسط زندگی می کنند [۲]. آلزایمر ۵ تا ۸ درصد از افراد ۶۰ سال و بالاتر را تحت تأثیر قرار می دهد و پیش بینی می شود تا سال ۲۰۳۰ بر ۸۲ میلیون نفر تأثیر بگذارد [۳] و تا سال ۲۰۵۰ به ۱۵۲ میلیون نفر افزایش یابد و در کشورهای با درآمد کم و متوسط افزایش قابل توجهی داشته باشد [۴]. تصویربرداری MRI یک معیار اولیه مکمل برای نظارت و تشخیص آلزایمر است. تجزیه و تحلیل تصاویر مغز MR معمولاً وقت گیر، گران قیمت و نیازمند تخصص و تجربه بالا است [۵]. بنابراین، روش های اتوماتیک و نیمه اتوماتیک برای تقسیم بندی آلزایمر توصیه می شود. به دلیل اهمیت این موضوع در این پژوهش روشی با سرپرست برای تشخیص بیماری آلزایمر در بافت مغزی است. در این پروژه، هدف ما تشخیص بیماری آلزایمر با کمک تصاویر MRI مغزی است. برای این منظور، تصاویر MRI دریافت شده و پیش پردازش می شوند. سپس برای ورود به شبکه های کانولوشنی آماده می شوند. چندین شبکه از پیش آموزش دیده با طراحی های مختلف آموزش داده می شود تا ساختار بهینه با بیشتری صحت تشخیص شناسایی شود [۶].

در سال های اخیر، پیشرفت های قابل توجهی در زمینه تشخیص زودهنگام و پیش آگهی بیماری آلزایمر (AD) صورت گرفته است. ظهور تکنیک های یادگیری ماشینی (ML) و یادگیری عمیق (DL) نقش مهمی در پیشبرد این حوزه از تحقیقات ایفا کرده است. به عنوان مثال، ژانگ و همکاران [۱] یک رویکرد مبتنی بر DL برای تمایز بین مغزهای مبتلا به آلزایمر و مغزهای سالم پیشنهاد کرد. روش آنها شامل استفاده از شبکه های عصبی کانولوشن (CNN)، نوعی معماری DL، برای توسعه یک مدل آموزش دیده و پیش بینی شده بود. رویکرد پیشنهادی برای تشخیص AD، اختلال شناختی خفیف (MCI) و مراحل اولیه آن ها شامل یک رمزگذار خودکار پشته ای، یک لایه رگرسیون نرم افزاری، و نیاز به حداقل نمونه های آموزشی برجسته گذاری شده است، بنابراین نیاز به تجربه قبلی گسترده را کاهش می دهد. اثربخشی این روش با استفاده از داده های تصویربرداری عصبی از ۳۱۱ شرکت کننده در مطالعه ابتکار تصویربرداری عصبی بیماری آلزایمر (ADNI) ارزیابی شد که شامل ۶۵ بیمار AD، ۶۷ بیمار MCI که بعداً به AD تبدیل شدند، ۱۰۲ بیمار غیر تبدیل کننده MCI (ncMCI) و ۷۷ بیمار مورد ارزیابی قرار گرفت. افراد کنترل عادی (NC) نتایج دقت ۸۸.۵۸٪ را در طبقه بندی باینری با استفاده از تصاویر MRI و توموگرافی انتشار پوزیترون (PET) و دقت ۴۷.۴۲٪ را در طبقه بندی ۴ کلاسه نشان داد.

بتکوتی و پل [۷] یک چارچوب جدید ترکیبی یادگیری عمیق چند کلاسه (DL) را با هدف تشخیص زودهنگام بیماری آلزایمر (AD) معرفی کردند. آنها از یک طبقه بندی خودکار رمزگذار k-Sparse (KSA) برای شناسایی مناطقی از مغز که دچار تخریب غیرفعال شده بودند، استفاده کردند. مطالعه آن ها شامل انجام آزمایش هایی با استفاده از ۱۵۰ اسکن MRI، همراه با تصاویر CSF و PET بود که از مطالعه ADNI به دست آمد. نتایج نشان داد که رویکرد KSA اصلاح شده از نظر دقت کلی هم از استراتژی پوشش صفر و هم از روش سنتی KSA بهتر عمل می کند. پیش بینی های جفت افزایش یافته به دقت ۸۳.۱۴۳٪ با ۱۰۰ ترکیب طبقه بندی کننده دست یافتند که از دقت ۷۱.۳۲۷٪ به دست آمده با ۵۰ ترکیب طبقه بندی کننده فراتر رفت.

آکاریا و همکاران [۸]، از یک سری تکنیک های کمی مانند فیلتر کردن، استخراج ویژگی، انتخاب ویژگی مبتنی بر آزمون t-student، و طبقه بندی مبتنی بر k-نزدیکترین همسایه (KNN) است. یافته های آن ها نشان می دهد که تکنیک استخراج ویژگی تبدیل Shearlet (ST) نتایج بهبود یافته ای را برای تشخیص آلزایمر در مقایسه با روش های جایگزین ارائه می دهد. مقصود و همکاران همکاران [۹]، یک سیستم پیشنهادی کارآمد با استفاده از یادگیری انتقالی برای طبقه بندی تصاویر با تنظیم دقیق شبکه کانولوشن از پیش آموزش دیده AlexNet کار می کند. معماری AlexNet بر روی مجموعه داده ImageNet متشکل از تصاویر متعلق به ۱۰۰۰ کلاس آموزش داده شده است. برای آموزش مدل از پیش آموزش دیده برای طبقه بندی تصاویر از دامنه هدف، لایه های CNN منتقل شده به خوبی روی مجموعه داده هدف تنظیم می شوند و ویژگی های سطح پایین را از ImageNet دست نخورده نگه می دارند.

مامون و همکاران [۱۰]، مدل های مبتنی بر یادگیری عمیق را برای تشخیص آلزایمر با استفاده از ۶۲۱۹ تصویر MRI مغزی توسعه دادند. مجموعه داده شامل تصاویری از درجات مختلف مغزهای زوال عقل و سالم است. چهار مدل یادگیری عمیق که در این مطالعه مورد استفاده قرار می گیرند عبارتند از: شبکه عصبی کانولوشن (CNN)، ResNet۱۰۱، DenseNet۱۲۱، و VGG۱۶. پس از تجزیه و تحلیل، مشاهده شد که CNN از سایر مدل ها بهتر عمل کرد و به دقت ۹۷.۶۰٪، فراخوانی ۹۷٪ و AUC ۹۹.۲۶٪ با خطای اسمی ۰.۰۹۱ دست یافت.

مروا و همکاران [۱۱]، یک روش مبتنی بر یادگیری عمیق را برای تشخیص دقیق و طبقه بندی مراحل آلزایمر ایجاد می کند. روش تجزیه و تحلیل پیشنهادی از معماری شبکه عصبی پیچیده (CNN) کم عمق و تصاویر MRI مغزی با وزندهی T۱ استفاده می کند. روش پیشنهادی نه تنها یک ماژول تشخیص آلزایمر سریع و دقیق را معرفی می کند، بلکه یک طبقه بندی عمومی (به عنوان مثال، اختلال شناختی نرمال در مقابل خفیف (MCI) در مقابل AD) و همچنین طبقه بندی جزئی ارائه می کند.

سینگ و همکاران [۱۲]، ز یک الگوریتم پیش پردازش و حذف سایر اجزای ناخواسته از MRI استفاده می کند. ثبت تمام تصاویر MRI در فضای MNI و نمونه برداری مجدد از برش ها به عادی سازی کل مجموعه داده کمک کرد. این مطالعه از روش های مبتنی بر ویژگی برای کار با ویژگی های کم بعدی استفاده می کند. آن ها از شبکه سبک VGG-۱۶ با وزن خالص تصویر به منظور استخراج خودکار ویژگی استفاده کردند. MRI های T۱-weighted برای تحقیق مورد استفاده قرار گرفتند که از


مجموعه داده‌های ADNI^۲ و ADNI^۳ دسترسی داشتند. در مقایسه با یک DNN معمولی، شبکه عصبی ترکیبی یکسان پیشنهادی آن‌ها به دقت و امتیاز F_۱ بهتری دست یافت.

تشخیص آلزایمر به دلیل شباهت در اسکن MRI بین بیماران AD و افراد سالم چالش برانگیز است. در حالی که مطالعات قبلی بر تقویت و اصلاح معماری‌های مختلف CNN یا مجموعه‌ای از مدل‌های CNN برای پیش‌بینی‌های تشخیصی دقیق AD متمرکز شده‌اند، رویکرد ما بر برجسته کردن شباهت‌های ساختاری در بین کلاس‌های مختلف تصویر آلزایمر (سالم، آلزایمر بسیار خفیف، آلزایمر خفیف، و آلزایمر متوسط) تأکید دارد. هدف اصلی این مطالعه ایجاد یک چارچوب مبتنی بر یادگیری عمیق (DL) برای تشخیص مراحل مختلف بیماری آلزایمر (AD) است. شبکه‌های عصبی کانولوشنال (CNN) در تحقیقات پردازش و تحلیل تصویر مغز مورد استفاده قرار می‌گیرند. این تحقیق روشی را معرفی می‌کند که از رویکرد CNN برای تعیین مرحله آلزایمر بر اساس الگوهای تصاویر MRI بیمار استفاده می‌کند. الگوریتم پیشنهادی مراحل متوالی را دنبال می‌کند، که با آماده‌سازی مجموعه داده‌ها و پیش‌پردازش شروع می‌شود، سپس ساخت، طراحی و تنظیم پارامتر مدل CNN را دنبال می‌کند. پس از آن، عملکرد مدل اندازه‌گیری و با سایر روش‌های پیشرفته مقایسه می‌شود.

۲- مواد و روش‌های

۲-۱- مجموعه داده‌ها

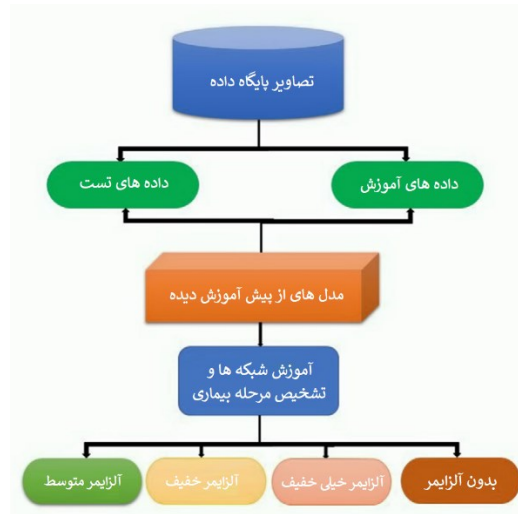
این پروژه تحقیقاتی شامل تجزیه و تحلیل تجربی اسکن‌های مغز مقطعی MR با وزن T_۱ است که داده‌های آن به صورت آزاد در دسترس عموم است. داده‌های اطن مطالعه از از پایگاه‌داده مطالعات تصویربرداری دسترسی باز (OASIS) است [۱۳]. داده‌های این مطالعه از پایگاه داده OASIS-۳، آخرین نسخه OASIS، که برای ارائه مجموعه داده‌های تصویربرداری عصبی آزادانه به محققان طراحی شده است، تهیه شده است. OASIS-۳ شامل داده‌های تصویربرداری عصبی طولی، بالینی، شناختی و نشانگرهای زیستی برای پیری طبیعی و بیماری آلزایمر (AD) است. مجموعه داده شامل مجموعاً ۶۴۰۰ تصویر است که بر اساس شدت آلزایمر در چهار کلاس طبقه‌بندی شده‌اند: بدون آلزایمر یا سالم (ND)، آلزایمر متوسط (MoD)، آلزایمر خفیف (MD) و آلزایمر بسیار خفیف (VMD) که تصاویر از بیماران مختلف تهیه شده است. هر کلاس به ترتیب شامل ۳۲۰۰، ۶۴، ۸۹۶ و ۲۲۴۰ تصویر برای سالم، آلزایمر متوسط، آلزایمر خفیف و آلزایمر بسیار خفیف است. توزیع تصاویر برای آموزش و آزمایش در هر دسته به همراه نمونه‌هایی از تصاویر MR برای چهار گروه در شکل ۱ نشان داده شده است.



شکل ۱: نمونه‌های تصویر MRI برای مراحل مختلف آلزایمر: (a) بدون آلزایمر یا سالم (ND)، (b) آلزایمر متوسط (MoD)، (c) آلزایمر خفیف (MD) و (d) آلزایمر بسیار خفیف (VMD)

۲-۲- چارچوب پیشنهادی

فلوچارت تحلیلی چارچوب پیشنهادی در شکل ۲ نشان داده شده است و شامل مراحل پردازش چندگانه است. مرحله اول پیش پردازش و تقویت داده ها است. پس از آن اصلاح و آموزش شبکه با معماری توسعه یافته CNN آن انجام می شود. جزئیات این مرحله شامل آموزش انتقالی، آموزش مدل و تنظیم پارامتر و در نهایت طبقه بندی است. در ادامه، جزئیات آن مراحل به طور کامل شرح داده شده است.



شکل ۲: نمایش فلوچارت برای چارچوب تحلیل پیشنهادی.


۲-۲-۱- پیش پردازش

گاهی اوقات کنتراست تصاویر MRI به دلایل مختلفی خراب می شود. تکنیک های بهبود تصویر معمولاً برای اصلاح یا بهبود توزیع پیکسل ها در شدت های مختلف برای حل این مشکل برای بهبود اسکن های MRI استفاده می شوند. از آنجایی که توزیع هیستوگرام تصاویر با یکدیگر متفاوت است، فرآیند کشش هیستوگرام (HS) روی تصاویر مجمله انجام شد. روش HS یک روش عادی سازی شدت بین اسکن است. معادله HS با رابطه ۱ مشخص شده است. نتیجه بهبود کنتراست در شکل ۳ نمایش داده شده است.

$$img_{out}(x, y) = \frac{img_{in}(x, y) - \min(img_{in}(x, y))}{\max(img_{in}(x, y)) - \min(img_{in}(x, y))}$$

رابطه ۱

پس از اعمال تبدیل فوق روی تصویر، مقادیر پیکسل گسسته ۰ تا ۲۵۵ به حالت پیوسته $[-1, 1]$ تغییر می کند:



شکل ۳: نتیجه بهبود کنتراست تصویر MRI مغزی. سمت چپ تصویر اصلی و سمت راست تصویر پس از بهبود کنتراست

۲-۲-۲- طراحی معماری عمیق پیشنهادی

معماری شبکه های عمیق پیشنهادی در شکل ۴ نشان داده شده است. پس از پیش پردازش، تصاویر در اندازه ماتریس ۱۰۰ در ۱۰۰ ذخیره شده و برای آموزش و آزمایش به CNN پیشنهادی ارائه شدند. مدل CNN پیشنهادی شامل یک ورودی، یک خروجی و چندین لایه طراحی شده است. به طور خاص، ۴ لایه کانولوشن (۲ بعدی) در این مطالعه به کار گرفته شد که هر یک شامل یک لایه ادغام حداکثر است. خروجی هر یک از لایه های ادغام وارد تابع فعالیت های ReLu می شود. با کاهش وضوح خروجی های هر لایه، لایه ادغام تغییر ناپذیری ترجمه را ارائه می دهد. در نهایت، لایه های تمام متصل، یک طبقه بند کامل را ایجاد می کند. بهینه سازی نتایج با تغییر مکرر پارامترهای تمام لایه های شبکه انجام شده است. معماری شبکه طراحی شده به صورت جدول ۱ است:

جدول ۱: خلاصه ای از تنظیمات پارامتر سیستم پیشنهادی ما.

پارامترها	شکل خروجی	لایه
۰	(۱۰۰،۱۰۰،۳)	ورودی
۱۶۶۴	(۹۶،۹۶،۶۴)	conv۲d
۰	(۴۸،۴۸،۶۴)	max_pooling۲d
۰	(۴۸،۴۸،۶۴)	Relu
۷۳۸۵۶	(۴۸،۴۸،۱۲۸)	conv۲d
۰	(۲۴،۲۴،۱۲۸)	max_pooling۲d
۰	(۲۴،۲۴،۱۲۸)	Relu
۲۹۵۱۶۸	(۲۴،۲۴،۲۵۶)	conv۲d
۰	(۱۲،۱۲،۲۵۶)	max_pooling۲d
۰	(۱۲،۱۲،۲۵۶)	Relu
۵۲۴۸۰۰	(۱۲،۱۲،۵۱۲)	conv۲d
۰	(۶،۶،۵۱۲)	max_pooling۲d
۰	(۶،۶،۵۱۲)	Relu
۰	۵۱۲۰۰	flatten
۵۱۲۰۱۰	۱۰	dense
۰	۱۰	dropout
۴۴	۴	Softmax

۲-۲-۳- یادگیری انتقالی

یادگیری انتقالی به فرایند انتقال دانش، مهارت ها و تجربیات از یک وظیفه یا محیط به وظایف یا محیط های دیگر اطلاق می شود [۱۴]. این نوع یادگیری به ارتباط و انتقال دانش پیشین به حل مسائل جدید و مواجهه با وظایف نوین می پردازد. یادگیری انتقالی می تواند از محیط های مختلفی مانند تحصیلی، شغلی یا زندگی روزمره رخ دهد و نقش مهمی در توسعه مهارت ها و تطبیق با چالش های جدید دارد. یادگیری انتقالی کمک می کند تا از دانش قبلی مدل های موفق بهره برده و مسائل جدید را حل کند. در این مطالعه از ۵ مدل معروف که در مسائل مختلف موفقیت های چشمگیری داشتند استفاده شده است. این مدل ها عبارتند از VGG۱۶، InceptionV۳، ResNet۵۰، DenseNet۱۲۱ و EfficientNetB۷. این شبکه ها در مسابقات بین المللی نتایج خیره کننده ای داشته و در بسیاری از مطالعات یادگیری انتقالی، به عنوان شبکه های خبره انتخاب شده اند.


۴- نتایج

هر یک از شبکه ها، برای ۱۰۰ دوره آموزش داده شده است که هر دوره شامل ۴۰ دسته است. داده ها به دو دسته آموزش (۸۰٪ داده ها) و آزمون (۲۰٪ داده ها) تقسیم شدند. از مجموعه آموزشی، ۱۶٪ از داده ها به عنوان یک مجموعه اعتبار سنجی استفاده می شود که هدف آن جلوگیری از بروز بیش برآزش و توقف زودهنگام است. پیاده سازی با زبان پایتون و با استفاده از کتابخانه های راجع نظیر numpy و scikitlearn انجام شده است. همچنین از کتابخانه Keras برای بخش های یادگیری عمیق استفاده شده است. برای اجرای کدهای نوشته شده، از محیط Google Colab و T4Gpu استفاده شده است.


هدف از ارزیابی مدل کمک به تصمیم گیری در مورد تعمیم یک مدل داده معین به داده های جدید است تا بتوانیم بین مدل های مختلف تمایز قائل شویم. برای این منظور به یک محاسبه معیار برای تعیین عملکرد مدل های مختلف نیز نیاز داریم. یک معیار پایه، دقت طبقه بندی (ACC) است که محاسبه می کند یک کلاس نمونه به درستی توسط مدل در مجموعه اعتبارسنجی پیش بینی شده است. علاوه بر این، از معیارهای اضافی مانند حساسیت (SEN) و ویژگی (SPE) نیز استفاده می شود. این معیارها به ترتیب به صورت زیر تعریف می شوند:

$$\begin{aligned} \text{ACC} &= \frac{\text{TN} + \text{TP}}{\text{TN} + \text{TP} + \text{FN} + \text{FP}} \\ \text{SEN} &= \frac{\text{TP}}{\text{TP} + \text{FN}} \\ \text{SPE} &= \frac{\text{TN}}{\text{TN} + \text{FP}} \end{aligned} \quad (1)$$


که در آن TP، TN، FN و FP به ترتیب نشان دهنده نمونه های مثبت واقعی، منفی واقعی، منفی کاذب و مثبت کاذب هستند. دستیابی به مدل پیشنهادی منجر به حساسیت و ویژگی ۱۰۰٪ شد. علاوه بر معیارهای کمی، عملکرد شبکه به صورت کیفی با استفاده از نمودارهای دقت و خطا در دوره ها آموزش نمایش داده می شود. این نمودارها در شکل های ۴ تا ۹ نمایش داده شده اند:




شکل ۴: نمودار صحت و خطای شبکه VGG۱۶




شکل ۵: نمودار صحت و خطای شبکه InceptionV۳




شکل ۶: نمودار صحت و خطای شبکه ResNet۵۰



شکل ۷: نمودار صحت و خطای شبکه DenseNet۱۲۱




شکل ۸: نمودار صحت و خطای شبکه EfficientNetBV




شکل ۹: نمودار صحت و خطای شبکه طراحی شده

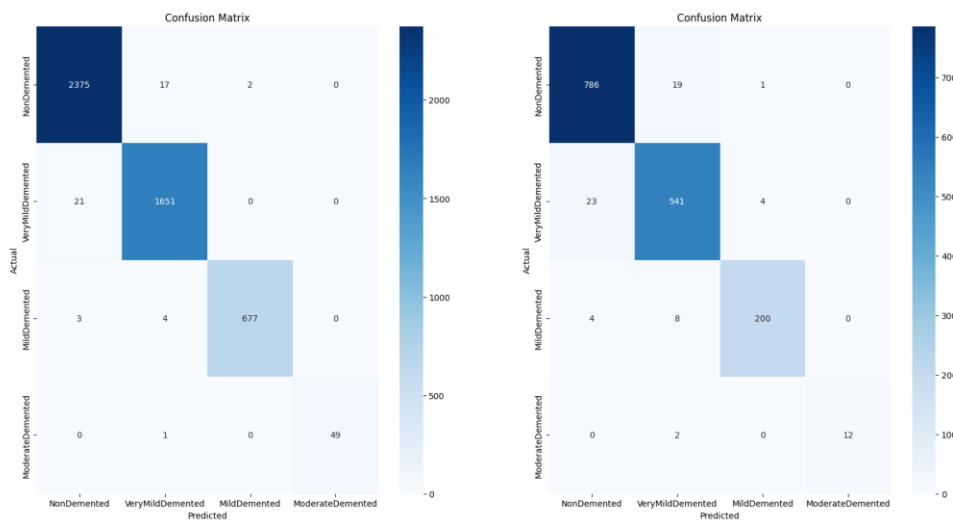
ماتریس های درهم ریختگی آموزش و آزمون شبکه ها نیز در شکل های ۱۰ تا ۱۵ نمایش داده شده است:




شکل ۱۰: ماتریس در هم ریختگی شبکه VGG۱۶. چپ برای داده های آموزش و راست برای داده های آزمون




شکل ۱۱: ماتریس در هم‌ریختگی شبکه InceptionV۳. چپ برای داده‌های آموزش و راست برای داده‌های آزمون



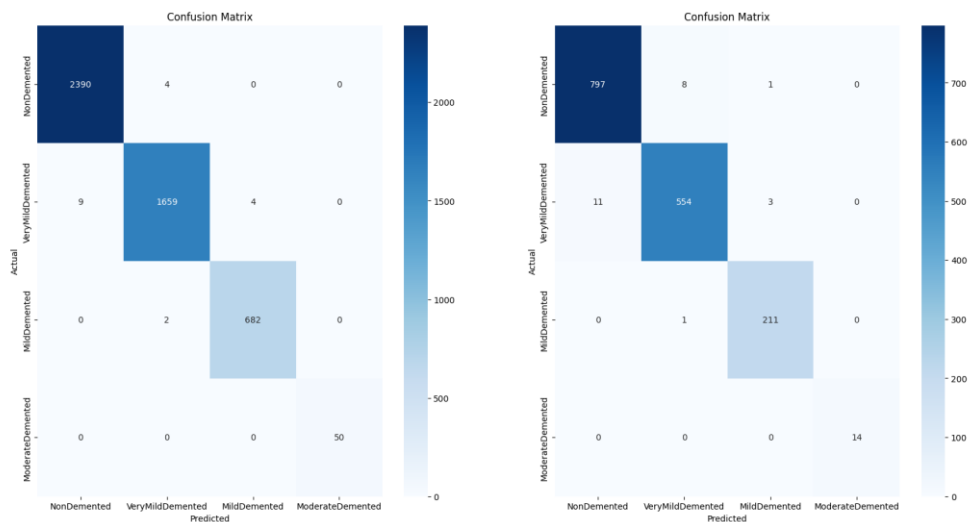
شکل ۱۲: ماتریس در هم‌ریختگی شبکه ResNet۵۰. چپ برای داده‌های آموزش و راست برای داده‌های آزمون



شکل ۱۳: ماتریس در هم‌ریختگی شبکه DenseNet۱۲۱. چپ برای داده‌های آموزش و راست برای داده‌های آزمون



شکل ۱۴: ماتریس در هم‌ریختگی شبکه EfficientNetB7. چپ برای داده‌های آموزش و راست برای داده‌های آزمون



شکل ۱۵: ماتریس در هم‌ریختگی شبکه طراحی شده. چپ برای داده‌های آموزش و راست برای داده‌های آزمون

جدول ۲، معیارهای صحت، حساسیت و مشخصه را برای هر یک از شبکه‌ها نمایش می‌دهد:

جدول ۲: ارزیابی مدل پیشنهادی در برابر سایر CNN که از یادگیری انتقالی استفاده می‌کنند.

آموزش			آزمون			
صحت	حساسیت	مشخصه	صحت	حساسیت	مشخصه	
۹۹.۰۴	۹۹.۷۱	۹۸.۳۰	۹۶.۸۸	۹۷.۵۱	۹۶.۶۹	VGG۱۶
۹۹.۱۷	۹۹.۵۵	۹۸.۴۱	۹۶.۴۴	۹۷.۶۳	۹۵.۶۸	InceptionV۳
۹۹.۰۰	۹۹.۶۴	۹۸.۴۶	۹۶.۱۹	۹۷.۲۷	۹۵.۷۲	ResNet۵۰
۹۹.۲۱	۹۹.۴۳	۹۸.۴۵	۹۶.۲۵	۹۷.۰۳	۹۵.۵۳	DenseNet۱۲۱
۴۹.۸۸	۵۳.۳۳	۴۶.۶۲	۵۰.۳۸	۵۳.۳۳	۴۶.۷۹	EfficientNetB۷
۹۹.۶۰	۹۹.۹۲	۹۸.۸۹	۹۸.۵۰	۹۸.۹۸	۹۷.۷۳	مدل پیشنهادی

بنابر نتایج حاصله، بهترین نتیجه مرتبط با شبکه پیشنهادی است که در فاز آزمون صحت ۹۸.۵۰٪ را نشان می دهد که حدود ۲ درصد از سایر شبکه های یادگیری انتقالی بهتر عمل می کند. علاوه بر این، حساسیت و مشخصه آن نیز از سایر شبکه ها در حدود ۲ درصد بهتر است.

۵- بحث و نتیجه گیری

این تحقیق منجر به توسعه یک روش مبتنی بر شبکه های یادگیری عمیق برای شناسایی موفقیت آمیز مرحله پیشروی بیماری آلزایمر چند طبقه با استفاده از تصاویر MR مغز شده است. روش پیشنهادی دقت، حساسیت و ویژگی را به ترتیب ۹۸.۵۰٪، ۹۸.۹۸٪ و ۹۷.۷۳٪ را نشان داد. اعتبار سنجی و آزمایش با استفاده از ۶۴۰۰ تصویر از مجموعه داده های MRI مغز انجام شد. استحکام روش با استفاده از تجزیه و تحلیل پارامترها تأیید شده است. دقت بالاتر رویکرد ما با استفاده از انتخاب مناسب معماری شبکه، کاربرد آن را برای پیش بینی مراحل مختلف بیماری آلزایمر برای گروه های سنی مختلف نشان می دهد. ما از الگوریتم های داده کاوی پیشرفته روی مجموعه داده های مختلف استفاده خواهیم کرد تا آنها را در کارهای آینده ترکیب کنیم تا عملکرد و اثربخشی پیش بینی AD در مراحل اولیه با استفاده از مجموعه داده ها و مراحل مختلف افزایش یابد.

مراجع

- [۱] F. Zhang, Z. Li, B. Zhang, H. Du, B. Wang, X. Zhang, Multimodal deep learning model for auxiliary diagnosis of alzheimer's disease, Neurocomputing ۳۶۱ (۲۰۱۹) ۱۸۵-۱۹۵.
- [۲] A. Mehmood, M. Maqsood, M. Bashir, Y. Shuyuan, A deep siamese convolution neural network for multi-class classification of alzheimer disease, Brain Sci. ۱۰ (۲) (۲۰۲۰) ۸۴.
- [۳] S.B. Shree, H. Sheshadri, Diagnosis of alzheimer's disease using naive bayesian classifier, Neural Comput. Appl. ۲۹ (۱) (۲۰۱۸) ۱۲۳-۱۳۲.
- [۴] Y. Zhang, Z. Dong, P. Phillips, S. Wang, G. Ji, J. Yang, T.-F. Yuan, Detection of subjects and brain regions related to alzheimer's disease using ۳d mri scans based on eigenbrain and machine learning, Front. Comput. Neurosci. ۹ (۲۰۱۵) ۶۶.
- [۵] A. Abrol, M. Bhattarai, A. Fedorov, Y. Du, S. Plis, V. Calhoun, A.D.N. Initiative, et al, Deep residual learning for neuroimaging: An application to predict progression to alzheimer's disease, J. Neurosci. Methods ۱۰۸۷۰۱ (۲۰۲۰).
- [۶] M.A. Ebrahimighahnavieh, S. Luo, R. Chiong, Deep learning to detect alzheimer's disease from neuroimaging: A systematic literature review, Comput. Methods Programs Biomed. ۱۸۷ (۲۰۲۰) ۱۰۵۲۴۲.
- [۷] M.P. Bhatkoti Pushkar, Early diagnosis of alzheimer's disease: A multi-class deep learning framework with modified k-sparse autoencoder classification.
- [۸] Acharya, U. Rajendra, et al. "Automated detection of Alzheimer's disease using brain MRI images—a study with various feature extraction techniques." Journal of Medical Systems ۴۳ (۲۰۱۹): ۱-۱۴.
- [۹] Maqsood, Muazzam, et al. "Transfer learning assisted classification and detection of Alzheimer's disease stages using ۳D MRI scans." Sensors ۱۹,۱۱ (۲۰۱۹): ۲۶۴۵.

- [١٠] Mamun, Muntasir, et al. "Deep Learning Based Model for Alzheimer's Disease Detection Using Brain MRI Images." ٢٠٢٢ IEEE ١٣th Annual Ubiquitous Computing, Electronics & Mobile Communication Conference (UEMCON). IEEE, ٢٠٢٢.
- [١١] Marwa, EL-Geneedy, et al. "An MRI-based deep learning approach for accurate detection of Alzheimer's disease." Alexandria Engineering Journal ٦٣ (٢٠٢٣): ٢١١-٢٢١.
- [١٢] Singh, Adwitiya Pratap, et al. "IHDNA: Identical Hybrid Deep Neural Networks for Alzheimer's Detection using MRI Dataset." ٢٠٢٣ ٣rd International Conference on Intelligent Communication and Computational Techniques (ICCT). IEEE, ٢٠٢٣.
- [١٣] Basheer, Shakila, Surbhi Bhatia, and Sapiyah Binti Sakri. "Computational modeling of dementia prediction using deep neural network: analysis on OASIS dataset." IEEE access ٩ (٢٠٢١): ٤٢٤٤٩-٤٢٤٦٢.
- [١٤] Salehi, Ahmad Waleed, et al. "A study of CNN and transfer learning in medical imaging: Advantages, challenges, future scope." Sustainability ١٥,٧ (٢٠٢٣): ٥٩٣٠.